



Data Science

Hands on - M4L2 | Aprendizaje supervisado
I: Regresión



→ soyhenry.com



Objetivos

- Examinar los supuestos fundamentales de la regresión lineal, evaluando su impacto en la validez del modelo y su aplicación en datos reales.
- Interpretar los coeficientes de regresión, analizando su significado y relevancia en la relación entre las variables independientes y dependientes.
- Evaluar el rendimiento del modelo mediante el coeficiente de determinación y métricas de error, comparando regresión lineal simple, múltiple y polinómica.





Agend a

COMENCEMOS →

#TEMAS

- .01 Introducción a la regresión lineal: supuestos y definiciones
- .02 Evaluación de rendimiento
- .03 Regresión lineal polinómica y regresión lineal múltiple
- .04 Homework





<->

¿Qué vimos en la lecture?





<01>

Introducción a la regresión lineal: supuestos y definiciones





Idea geométrica de la regresión

La regresión lineal busca una **recta** que describa cómo cambia una variable dependiente (y) según una independiente (x).

Fórmula: $y = \beta_0 + \beta_1 x + \epsilon$

- $\beta_0 \rightarrow$ intercepto (valor de y cuando $x=0$)
 - $\beta_1 \rightarrow$ pendiente (cuánto cambia y por cada unidad de x)
- Ejemplo CityScoot:** $x =$ temperatura, $y =$ cantidad de viajes.




Intuición geométrica

Cada punto representa un día con su temperatura y número de viajes.

La recta ajustada minimiza la **suma de errores al cuadrado**:

→ cuanto menor la distancia entre los puntos reales y la recta, mejor el modelo.

Pendiente positiva: más calor → más viajes.





Supuestos del modelo

Para que el modelo sea válido, deben cumplirse ciertos supuestos:

- ★ **Linealidad:** la relación entre x e y se aproxima a una recta.
- ★ **Homocedasticidad:** varianza constante de errores (sin "embudo").
- ★ **Independencia de errores:** los residuos no deben tener patrón.
- ★ **Normalidad:** los residuos siguen una distribución normal.
- ★ **Ausencia de multicolinealidad:** las x no deben aportar la misma información.





Interpretación de coeficientes

Ecuación: rides = 250 + 18.5 × temp

- $\beta_0 = 250 \rightarrow$ viajes base aun con baja temperatura.
- $\beta_1 = 18.5 \rightarrow$ por cada grado más, +18.5 viajes.

Sentido práctico: cada coeficiente explica cuánto influye una variable en la demanda.





Cálculo de β_0 y β_1

Ejemplo con 5 días:


Temp = [10,15,20,25,30] → Viajes = [450,540,620,710,800]

Resultado: $\beta_1 = 17.4$ y $\beta_0 = 276$

Modelo final: rides = 276 + 17.4 × temp

→ Con 0 °C → 276 viajes esperados.

→ Por cada grado más → +17.4 viajes.





<02>

Evaluación de rendimiento






Evaluar el rendimiento del modelo

Coeficiente de determinación (R^2): mide cuánta variabilidad de y explica el modelo.

- $R^2 = 1 \rightarrow$ ajuste perfecto.
- $R^2 \approx 0 \rightarrow$ modelo casi no explica nada.



Más allá del R²

R² no mide el **error real**, solo el grado de explicación.

Por eso se complementa con:


- **MAE (Error Absoluto Medio)**
- **RMSE (Raíz del Error Cuadrático Medio)**
Ambas expresan el error en las mismas unidades que y (ej. "viajes").





MAE y RMSE

- **MAE:** promedio del error absoluto.
→ "Cuánto se equivoca el modelo, en promedio."
- **RMSE:** similar, pero penaliza más los errores grandes.
→ "Sensibilidad ante grandes desvíos."
- **CityScoot:**
 $\text{MAE} = 18 \rightarrow$ se equivoca en promedio 18 viajes.
 $\text{RMSE} = 18.44 \rightarrow$ penaliza los errores grandes.





Comparación de métricas

Métrica	Qué mide	Cuándo usarla
R^2	% de variabilidad explicada	Comparar poder explicativo
MAE	Error medio en unidades reales	Fácil de interpretar
RMSE	Error penalizado por magnitud	Detectar errores grandes





<03>

Regresión lineal polinómica y regresión lineal múltiple



Regresión polinómica

A veces la relación **no es lineal**.

Ejemplo CityScoot:

- A medida que sube la temperatura, la demanda crece, pero cae con calor extremo ($> 35^{\circ}\text{C}$).

Solución: agregar un término cuadrático o cúbico (temp^2 , temp^3).
→ Captura **curvas** de comportamiento real.



Regresión lineal múltiple

La demanda depende de más factores:

Modelo: rides = $\beta_0 + \beta_1\text{temp} + \beta_2\text{rain} + \beta_3\text{marketing} + \beta_4\text{price}$

Permite medir efectos simultáneos:

- +500 USD en marketing → +40 viajes.
- +5 mm de lluvia → -30 viajes.
Refleja mejor la complejidad del fenómeno real.





Regularización Ridge y Lasso

Más variables = riesgo de **sobreajuste** y **multicolinealidad**.

- **Ridge:** reduce coeficientes → más estables.
- **Lasso:** puede llevar algunos coeficientes a **0** → selección automática de variables.

Ejemplo CityScoot:

Ridge estabiliza predicciones con variables redundantes.

Lasso simplifica el modelo, dejando solo las variables más relevantes.





<DATA SCIENCE/>

Vayamos a la práctica



Homework



→ soyhenry.com



Consigna

La empresa ficticia **RetailBoost** desea comprender mejor el comportamiento de sus clientes. Para ello, se dispone de un dataset con información demográfica y de consumo. El objetivo es **predecir el monto de gasto mensual de los clientes** en la tienda online, a partir de variables como edad, ingresos, historial de visitas y otros factores.

Tu tarea será:

1. Realizar un **EDA exploratorio** sobre el dataset.
2. Ajustar al menos **dos modelos de regresión** (ej. regresión lineal simple, múltiple o polinómica).
3. Evaluar el rendimiento de los modelos utilizando métricas como **R², MAE y RMSE**.
4. Interpretar los resultados, explicando qué variables parecen influir más en el gasto mensual.





Tareas a realizar

1. Importar y explorar correctamente el dataset.
2. Mostrar la distribución de la variable objetivo (`monthly_spent`) y de las variables predictoras principales.
3. Ajustar al menos **un modelo de regresión lineal simple y uno múltiple**.
4. Calcular las métricas R^2 , MAE y RMSE en un conjunto de prueba.
Explicar de forma breve qué tan bien se ajusta el modelo y si los errores son razonables.





Extra credits

- Probar una **regresión polinómica** para capturar relaciones no lineales.
- Visualizar **y vs. y_pred** y el gráfico de **residuales** para verificar los supuestos de la regresión.
- Comparar el rendimiento entre distintos modelos en una tabla resumen.



HENRY



#OpenQuestion



¿Preguntas?



→ soyhenry.com

~~HENRY~~

¡Muchas gracias!



→ soyhenry.com